


REIM 项目技术精讲

Recovery-Enhanced Imitation Learning for Robust Embodied Robot Manipulation



Meta-World PickPlace · MuJoCo Sawyer · ACT + Causal LSTM + Recovery Imitation

技术说明、实验口径、代码地图与答辩 FAQ

2026-08-04

目录

1. 0. 先用一分钟讲清楚 REIM
2. 1. 项目到底解决什么任务
3. 2. 为什么只用 ACT 仍然会失败
4. 3. REIM 的一个故事：选择性恢复闭环
5. 4. 模块一：状态版 ACT 名义策略
6. 5. 模块二：因果 LSTM 风险监测器
7. 6. 模块三：触发对齐的恢复模仿策略
8. 7. 运行时控制权如何切换
9. 8. Baseline 为什么这样设计
10. 9. 评测协议为什么可信
11. 10. 实验结果应该怎样解释
12. 11. 一个真实仿真 episode 如何恢复
13. 12. 这个方案的创新点应怎样讲
14. 13. 当前证据边界与局限
15. 14. 复现实验的完整流程
16. 15. 代码地图
17. 16. 答辩常见问题
18. 17. 最后一句话

Recovery-Enhanced Imitation Learning for Robust Embodied Robot Manipulation

生成日期：2026-08-04

适用场景：项目答辩、组会汇报、论文方法讲解、代码交接与复现实验


0. 先用一分钟讲清楚 REIM

REIM 解决的是 Meta-World PickPlace 任务中的一个具体问题：一个只在专家示范分布上学习的机器人策略，在实际闭环执行时一旦受到动作误差、观测误差或物体位移，后续观测就会偏离训练分布，原策略可能继续执行已经失效的动作序列，最终抓取失败、轨迹漂移或超时。

当前项目不是把所有能力塞进一个大网络，而是把控制责任拆成三个明确角色：


19. **状态版 ACT (Action Chunking with Transformers)** 负责正常的抓取、搬运和放置。
20. **因果 LSTM 风险监测器**只读取最近 10 个已发生状态，估计近期进入失败事件的风险。
21. **触发对齐的恢复模仿策略**在风险超过阈值时接管控制，尝试从真实触发分布中的状态继续完成任务。

其部署闭环可以概括为：



核心结果是在相同的 1,000 个冻结 Meta-World 扰动任务上，ACT 成功率为 **73.4%**，完整 REIM 为 **90.4%**，配对提升 **17.0 个百分点**；170 个 ACT 失败任务被救回，0 个 ACT 原本成功任务被损害。

必须保持的科研口径：当前正式恢复器是监督式 trigger-aligned recovery imitation actor，不是强化学习策略；实验是 Meta-World/MuJoCo 中的模拟 Sawyer，不是实体机器人；约 99% 的恢复触发位于首次抬升之前，因此当前证据主要支持“早期风险纠偏与任务恢复”，不能外推为任意掉落后的通用修复。



1. 项目到底解决什么任务

1.1 Benchmark 与机器人

- Benchmark: Meta-World MT1。
- 用户指定的历史任务名: PickPlace-v2。
- 当前 Meta-World 3.1.1 中实际执行的维护版本: pick-place-v3。
- 机器人: MuJoCo 中的 Sawyer 7 自由度机械臂。
- 任务过程: 接近物体、闭合夹爪、抬升物体、搬运到目标区域并放置。
- 单个 episode 最大长度: 200 步。
- 环境成功信号: Meta-World 任务成功标志; 语义距离阈值配置为 0.07 m。

PickPlace-v2 到 pick-place-v3 是 API 维护版本映射, 不代表项目更换了任务。代码会同时记录 requested task 和实际运行的环境标识, 避免把不存在的旧注册名写成已直接执行。

1.2 状态与动作

默认策略输入是一个 21 维语义状态:

区间	维数	内容
s[0:7]	7	Sawyer 关节位置 qpos
s[7:10]	3	末端执行器位置 XYZ
s[10:14]	4	末端执行器四元数 WXYZ
s[14:17]	3	被操作物体位置 XYZ
s[17:20]	3	目标位置 XYZ
s[20]	1	夹爪开合状态

因此

$$s_t \in \mathbb{R}^{21}.$$

动作是四维连续控制量：

$$a_t = [\Delta x_t, \Delta y_t, \Delta z_t, g_t] \in [-1, 1]^4,$$

前三维控制 TCP 的笛卡尔增量，最后一维控制夹爪。

环境也提供 Meta-World 原始 39 维观测模式，但当前正式模型和论文结果使用 21 维语义状态。这意味着项目研究的是**状态观测下的鲁棒控制**，而不是视觉端到端操作。

1.3 扰动模型

项目向闭环执行注入三类扰动：

- 22. **动作噪声**：在 ACT 或恢复策略输出后叠加高斯噪声。
- 23. **观测噪声**：对送入策略与监测器的状态增加高斯误差。
- 24. **物体扰动**：在 episode 中对物体位置施加一次模拟位移。

主实验的 20% 扰动对应：

- 动作噪声标准差 0.08；
- 观测噪声标准差 0.005；
- 物体位移标准差 0.02 m。

鲁棒性实验把扰动等级扩展到 0%、10%、20%、30% 和 40%。所有方法在同一条件下消费同一批序列化任务状态和扰动日程，从而尽量把比较差异归因于控制器，而不是任务随机性。

2. 为什么只用 ACT 仍然会失败

模仿学习的训练目标通常是在专家分布上最小化动作误差：

$$\min_{\theta} \mathbb{E}_{(s, a^E) \sim \mathcal{D}_E} [\ell(\pi_{\theta}(s), a^E)].$$

但部署时状态由策略自己的历史动作决定：

$$s_{t+1} \sim P(\cdot \mid s_t, \pi_{\theta}(s_t)).$$

一旦某一步动作有误，机器人将进入专家数据很少覆盖的新状态；新状态又可能产生更差动作，误差会沿时间累积。这就是闭环中的 covariate shift / compounding error。

ACT 比逐步 BC 更强，因为它一次预测一段动作并进行时间集成，能减少短视和抖动；但它仍然是一个**名义策略**：它主要学习成功示范的轨迹结构，没有天然机制判断“当前动作块已经不再适合现在的物体位置”。当物体突然移动时，之前预测的动作块可能继续把机械臂带向旧位置。

REIM 的设计出发点不是要求 ACT 覆盖所有失败，而是承认名义策略有明确工作域，并在风险增大时进行责任切换。

3. REIM 的一个故事：选择性恢复闭环

REIM 的核心不是三个互不相关的网络，而是一个围绕**何时切换控制权**构造的闭环：

25. ACT 给出正常任务动作。
26. LSTM 同时从历史状态判断轨迹是否正在进入失败事件。
27. 低风险时不干预，保留 ACT 的名义能力。
28. 高风险时启动恢复 option。
29. 恢复策略训练数据专门来自这种“真实会触发的状态”，减少训练状态和部署触发状态之间的错位。

这形成了两个重要的分布对齐：

- **检测器对齐**：用受到动作、观测和物体扰动的 ACT rollout 训练，而不是只用专家轨迹。
- **恢复器对齐**：从 ACT+LSTM 在线触发时刻保存完整 MuJoCo 状态，再由专家从该状态继续，训练数据直接覆盖恢复器真正接管的位置。

因此项目最有价值的思想可以写成：

不让恢复策略在任意人工构造状态上学习，而让它在部署门控实际访问的触发分布上学习；再用因果时序门控把名义控制和恢复控制组合成一个选择性闭环。

4. 模块一：状态版 ACT 名义策略

4.1 为什么选择 ACT

PickPlace 包含接近、抓取、抬升、搬运、放置等相互关联的连续阶段。单步 MLP 每次只拟合当前动作，容易产生局部抖动；ACT 直接预测未来动作块，更适合表达“先下探、再闭爪、再抬升”这样的短期动作结构。

当前 ACT 配置为：

参数	数值
状态维数	21
动作维数	4
动作块长度	20
Transformer 隐藏维数	256
注意力头数	8
CVAE encoder 层数	3
decoder 层数	4
FFN 维数	1,024
潜变量维数	32
Dropout	0.1

参数量

6,627,908

4.2 训练时的 CVAE

对每个状态，数据加载器构造长度 20 的未来专家动作块

$$A_t^E = [a_t^E, a_{t+1}^E, \dots, a_{t+19}^E].$$

轨迹尾部不足 20 步的位置使用 padding mask，不把填充值计入重建误差。CVAE posterior encoder 接收 [CLS, 当前状态, 未来动作块]，输出潜变量分布：

$$q_\phi(z | s_t, A_t^E) = \mathcal{N}(\mu_\phi, \text{diag}(\sigma_\phi^2)).$$

Transformer decoder 使用状态 token、潜变量 token 和 20 个可学习 action query，预测完整动作块：

$$\hat{A}_t = \pi_{\text{ACT}}(s_t, z).$$

训练损失为掩码后的 L1 重建加 KL 正则：

$$\mathcal{L}_{\text{ACT}} = \mathcal{L}_{L1}(\hat{A}_t, A_t^E) + \beta D_{KL}(q_\phi(z | s_t, A_t^E) \| \mathcal{N}(0, I)),$$

其中 $\beta=10$ 。训练 200 epoch，batch size 256，学习率 10^{-4} ，weight decay 10^{-4} ，使用 trajectory-grouped 的 90%/10% 划分，避免同一条轨迹的相邻状态同时进入训练和验证。

4.3 推理与时间集成

推理阶段没有未来专家动作，因此丢弃 posterior encoder，固定

$$z = 0.$$

每一步都会预测一个新的 20 步动作块。对同一个执行时刻，多个历史动作块会给出重叠预测，代码使用指数权重组合：

$$a_t = \frac{\sum_i \exp(-mi) \hat{a}_t^{(i)}}{\sum_i \exp(-mi)}, \quad m = 0.05.$$

这减少了单个动作块造成的尖锐变化。每次从 ACT 切到恢复或从恢复返回 ACT 时，动作块历史都会被清空，防止未执行的旧轨迹建议继续污染后续动作。

实现中重叠提案按“最早生成 → 最新生成”排列，因此上式的 $i=0$ 对应最早但仍有效的提案，它获得最大权重；这是一项需要在复现时保持一致的实现细节，而不是默认“最新提案权重最大”。

4.4 ACT 数据与训练结果

- 500 条 Meta-World scripted Sawyer expert 成功轨迹；
- 示范成功率 100%；
- 共 25,969 个 transition；
- 平均轨迹长度 51.938 步；
- 轨迹长度范围 44–62 步；

- 最佳验证 action L1 为 0.004013。

这个结果说明 ACT 能拟合名义技能，但验证动作误差小不等价于闭环扰动下成功率高，因此仍需端到端评测。

5. 模块二：因果 LSTM 风险监测器

5.1 失败数据如何生成

冻结 ACT 后执行 2,000 个扰动 episode，扰动配置为：动作噪声 0.15、观测噪声 0.01、物体位移概率 0.02、位移幅度 0.04 m。

数据统计：

- 2,000 个 episode；
- 285,443 个时序窗口；
- episode 成功率 39.65%；
- 1,511 个 episode 发生物体扰动；
- 正标签比例 64.09%。

5.2 在线失败事件定义

事件标签器仅使用当前和过去的测量，规则包括：

30. 环境显式报告物体掉落；
31. 物体或机械臂超出工作空间；
32. episode 超时或失败终止；
33. 机械臂曾靠近物体，但之后远离且未抬升，判为抓取失败；
34. 与物体发生交互后，物体到目标的距离长期没有至少 0.004 m 的变化；
35. 交互后相对初始目标距离产生超过 0.10 m 的错误偏离。

进度和偏离规则只在确认物体已经移动或抬升后启用，避免把正常的抓取前接近阶段误标为“没有进度”。

5.3 输入窗口与预测目标

在时刻 t ，输入窗口严格结束于当前时刻：

$$X_t = [s_{\max(0, t-9)}, \dots, s_t].$$

早期不足 10 步的窗口右侧补零，并显式传入有效长度，LSTM 通过 `pack_padded_sequence` 忽略 padding。

监督目标是未来 10 步的 inclusive event target：

$$y_t = \mathbf{1}\{\exists j \in [t, t+10], e_j = 1\}.$$

注意目标可以查看未来事件，但输入绝不包含未来状态，因此不存在输入泄漏。由于区间包含 t ，标准分类指标同时包含“事件已经发生”和“事件即将发生”的窗口，所以项目把该模型严谨地称为**因果风险监测器**，而不是纯粹的长时域预测器。

5.4 网络与训练

结构为：

```

10 × 21 状态序列
    |
    LSTM hidden=128, layers=1
    |
    Linear 128→64 + ReLU + Dropout(0.1)
    |
    Linear 64→1
    |
    Sigmoid
  
```

使用带自动正样本权重的 BCEWithLogitsLoss：

$$\mathcal{L}_{det} = -w_+ y \log \sigma(l) - (1 - y) \log(1 - \sigma(l)).$$

训练最多 50 epoch，batch size 512，学习率 5×10^{-4} ，trajectory-grouped 80%/20% 划分，按最低验证 BCE 选择 checkpoint。部署阈值冻结为 $\tau_{on}=0.20$ 。

5.5 如何理解检测指标


在阈值 0.20、56,253 个验证窗口上：

- Accuracy: 89.6%;
- Precision: 91.8%;
- Recall: 92.3%;
- F1: 92.1%;
- 混淆矩阵: TN=16,352, FP=3,038, FN=2,832, TP=34,031。

但 86.1% 的正窗口对应 $offset=0$ ，即事件在当前时刻已经发生。只保留严格未来事件

后，precision/recall/F1 为 53.5%/68.3%/60.0%；在 trajectory 级别，191/258 条事件轨迹能在第一个事件之前告警，比例 74.0%，最新告警提前量中位数为 1 步。

这说明 LSTM 的主要价值是提供一个闭环风险信号，而不是证明它能提前很多步准确预测所有失败。是否真正有用必须由 REIM 端到端成功率和干预负担共同验证。



Measured on failure validation split (deployment threshold = 0.20)

风险监测器混淆矩阵

6. 模块三：触发对齐的恢复模仿策略

6.1 为什么不能随便采恢复数据

如果人为随机化状态后训练恢复器，训练分布可能和 LSTM 真正触发时的状态完全不同。REIM 使用以下闭环采集过程：

36. 在 20% 混合扰动下运行 ACT。
37. LSTM 风险达到较宽松的采集阈值 $\tau_{\text{collect}}=0.10$ 时，保存完整 MuJoCo snapshot。
38. snapshot 包含 qpos/qvel、mocap、控制量、目标和任务 bookkeeping，能够精确恢复该动态状态。
39. 从同一 snapshot 继续运行 Meta-World scripted expert。
40. 只有最终成功的专家 continuation 才产生监督状态—动作对。
41. 训练 bank 与验证 bank 使用不相交的 episode seeds。

较低的采集阈值用于扩大可恢复状态覆盖；部署阈值 0.20 则用于控制实际干预负担。两者有意分开，不是调参错误。

6.2 数据规模

数据	尝试 episode	触发 snapshot	可用成功 continuation	状态—动作对
训练	1,000	985	978	42,386
验证	200	193	192	8,212

训练和验证按照触发轨迹分组，不把同一 continuation 的相邻状态拆到两侧。

6.3 恢复 actor

部署策略是确定性 MLP：

```
state 21
→ Linear 256 → tanh
→ Linear 256 → tanh
→ Linear 4
→ clip[-1,1]
```

参数量为 72,452。训练目标为 Smooth L1：

$$\mathcal{L}_{rec}(\psi) = \frac{1}{|\mathcal{D}_{rec}|} \sum_{(s, a^E)} \text{SmoothL1}(\pi_{rec, \psi}(s), a^E).$$

训练 40 epoch，batch size 512，学习率 10^{-3} ，输入状态增加标准差 0.005 的高斯增强，按照 trajectory-disjoint 验证 Smooth L1 选择模型；最佳验证损失为 0.006391。

最终 imitation_recovery.pt 只包含 actor、归一化信息、动作边界和 provenance，不包含 critic、随机 log standard deviation、optimizer 或 rollout buffer。导出审计在 42,386 个训练状态、8,212 个验证状态和 10,000 个确定性随机支持状态上比较源 actor 与导出 actor，共 60,598 个状态，动作最大误差为 0。

6.4 为什么当前恢复器不是 RL

当前正式模型记录：

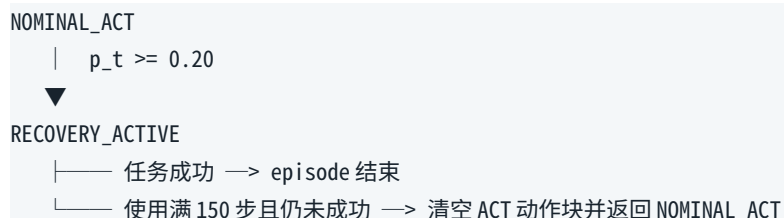
- 强化学习环境交互步数：0；
- policy-gradient update：0；
- critic：无；
- 优化目标：监督 Smooth L1。

因此正确称呼是“trigger-aligned supervised recovery imitation”。项目中保留的 Stable-Baselines3 兼容代码和旧容器不改变最终部署策略的算法属性。

7. 运行时控制权如何切换

7.1 两个控制模式

控制器可以视为状态机：



最终协议设置：

- 触发阈值 `failure_threshold = 0.20`；
- 恢复预算 `recovery_budget = 150`；
- 最小恢复步数 `recovery_min_steps = 150`；
- 风险清除步数 `recovery_clear_steps = 200`；
- 释放阈值 `recovery_exit_threshold = 0`。

由于 `min_steps == budget` 且 `clear_steps > budget`，恢复中途不会因为短暂的风险下降而提前退出。换言之，一旦恢复器接管，它会持续控制到任务成功或 150 步预算耗尽。

7.2 为什么采用持久接管

触发后只执行几步恢复动作再交还 ACT，可能出现两类问题：

42. LSTM 风险暂时下降，但机器人仍未回到 ACT 熟悉的状态；
43. ACT 内部仍保存切换前生成的动作块，重新接管后可能执行过期建议。

项目因此使用持久 option，并在所有 hand-off 处清空 ACT temporal ensemble。代价是误报时可能浪费较多步数，所以论文同时报告干预率和平均步数，而不只报告成功率。

7.3 简化伪代码

```
state = env.reset()
history = []
mode = "ACT"

while not done:
    history.append(state)
    risk = detector(last_10(history))

    if mode == "ACT" and risk >= 0.20:
        mode = "RECOVERY"
        act.reset_temporal_ensemble()
        recovery_steps = 0

    if mode == "RECOVERY":
        action = recovery_actor(state)
        recovery_steps += 1
    else:
        action = act.temporal_ensemble_action(state)

    state, success, done = env.step(action)

    if success:
        break
    if mode == "RECOVERY" and recovery_steps >= 150:
        mode = "ACT"
        act.reset_temporal_ensemble()
```

8. Baseline 为什么这样设计

正式主表使用四种方法：

44. **ACT**：没有任何干预，回答“名义模仿策略本身能做到什么”。
45. **ACT + Random Reset**：检测到启发式失败事件后，重新开始一个 fresh task retry，回答“额外再试一次是否已经足够”。重试使用保留的确定性 offset seed，不与同一次恢复等价。
46. **ACT + Heuristic Recovery**：使用与 REIM 完全相同的恢复 actor，但由语义启发式触发，回答“只要有恢复器，随便一个门控是否就够了”。启发式需要模拟器级物体交互、目标距离和显式失败信息。
47. **REIM**：LSTM 门控 + 同一个恢复 actor，回答“学习的时序门控是否优于强语义规则”。

这种设计把主要论证拆成两层：

- ACT → Heuristic Recovery 的大幅提升主要说明恢复动作本身有效；
- Heuristic Recovery → REIM 的提升与更低干预率说明学习的时序仲裁有额外价值。

没有把“Detector only”放进论文主故事，因为检测到风险后如果只是停止或不提供有效动作，它不是一个完整控制方案，也不能回答恢复机制是否有效。

9. 评测协议为什么可信

9.1 Common Random Numbers

主实验不是让每种方法各自随机运行 1,000 次，而是预先冻结 1,000 个 CRN episode specification。每个 specification 包含：

- 任务身份；
- 初始 MuJoCo 状态；
- episode seed；
- 扰动发生时刻与数值；
- 对应 SHA256。

同一 episode index 下的所有方法面对同一初态和扰动，能够进行逐 episode 配对比较。

9.2 指标定义

任务成功率：

$$\text{SuccessRate} = \frac{\text{\#task success}}{\text{\#episodes}}.$$

REIM/启发式恢复的 intervention outcome：

$$\text{RecoveryRate} = \frac{\text{\#task success while recovery active}}{\text{\#recovery interventions}}.$$

随机重置报告的是 post-reset completion / reset，分母和语义不同，因此表中明确标为重置结果而不是同一类恢复率。

成功率区间使用 Wilson 95% CI；比率和平均步数使用 episode bootstrap。方法差异使用配对 bootstrap；匹配门控审计对二元配对结果使用 exact two-sided McNemar/binomial test。

10. 实验结果应该怎样解释

10.1 主结果


主条件为 20% 混合扰动，每种方法 1,000 个相同 episode：

方法	任务成功率	95% CI	干预结果	干预率	平均步数
ACT	73.4%	[70.6, 76.0]%	—	—	93.3
ACT + Random Reset	81.3%	[78.8, 83.6]%	74.5%	73.2%	93.3
ACT + Heuristic Recovery	87.7%	[85.5, 89.6]%	83.3%	73.1%	72.8
REIM	90.4%	[88.4, 92.1]%	85.3%	65.5%	69.3

配对结论：

- REIM 相比 ACT: +17.0 pp, 95% CI [+14.7,+19.3] pp;
- 170 个 ACT 失败 episode 被 REIM 救回;
- 0 个 ACT 成功 episode 被 REIM 损害;
- 相比 Random Reset: +9.1 pp, CI [+6.1,+12.1] pp;
- 相比 Heuristic Recovery: +2.7 pp, CI [+0.7,+4.8] pp;
- REIM 比启发式门控少干预 76 个 episode, 干预负担相对下降 10.4%。

最重要的不是“REIM 只比启发式高 2.7 个点”，而是完整的 Pareto 关系：**成功率更高，同时干预次数更少，平均完成步数也更低。**



主结果、干预负担与鲁棒性

10.2 鲁棒性

每个噪声等级使用 200 个配对 episode：

扰动等级	ACT	REIM	提升
0%	100.0%	100.0%	0.0 pp
10%	97.0%	99.5%	+2.5 pp
20%	76.5%	92.0%	+15.5 pp
30%	53.5%	79.5%	+26.0 pp
40%	31.5%	63.5%	+32.0 pp


随着扰动变强，ACT 的成功率快速下降，而 REIM 的相对收益扩大。这符合系统设计目标：无扰动时不需要恢复，两者都能完成；偏离名义分布越远，风险触发和恢复的价值越明显。

10.3 门控贡献

在独立的 200 episode post-freeze bank 上：

- 启发式门控：成功率 86.0%，干预率 76.0%；
- LSTM $\tau=0.175$ ：成功率 92.5%，干预率 76.5%，相同干预负担下提升 +6.5 pp, $p=0.0044$ ；
- 冻结部署点 $\tau=0.20$ ：成功率 90.5%，干预率 63.5%，相对启发式提升 +4.5 pp, $p=0.0490$ 。

$\tau=0.175$ 的分析不是重新选择主实验阈值，而是证明在近似相同干预负担下，LSTM 仍能选择更有价值的介入时机。



Separate paired Meta-World diagnostic • $n=200$ • not used for selection

门控阈值敏感性

11. 一个真实仿真 episode 如何恢复


Figure 5 使用同一个初始任务和同一个物体位移扰动，seed 为 8,300,042：

48. $t=0$: ACT 与 REIM 从完全相同的状态开始；
49. $t=3$: 物体发生 0.048 m 位移；
50. ACT 继续沿失效轨迹执行，到 $t=200$ 超时失败；
51. REIM 在 $t=9$ 监测到风险概率 0.259，超过阈值 0.20；
52. 恢复策略接管 53 步，重新抓取、抬升并搬运；
53. REIM 在 $t=62$ 达到任务成功。

这是一条单独的定性轨迹，只用于解释机制，不用于估计平均成功率。图像是直接来自 Meta-World/MuJoCo 渲染的 Sawyer RGB frame，不是实体照片，也不是生成式模型合成图。

Paired Sawyer PickPlace rollout: ACT failure vs. REIM recovery

Meta-World/MuJoCo simulation frames · separate qualitative seed 8300042 · noise 0.2 · $\tau_{on} = 0.20$



ACT 失败与 REIM 恢复的配对操作序列

12. 这个方案的创新点应怎样讲

不要把创新描述成“用了 ACT、LSTM 和 MLP”三个网络的简单堆叠。更准确的三层创新是：

12.1 触发分布对齐的恢复学习

恢复数据不是离线随机构造，而是由冻结 ACT+LSTM 在线运行产生；采集状态就是恢复器将来可能接管的状态。它把 recovery policy 的训练分布与 controller arbitration 的访问分布连接起来。

12.2 因果时序风险门控

门控只使用最近 10 个已发生状态，不依赖未来状态；它学习动作误差、物体位移和轨迹进展共同形成的时序风险，而不是只看单帧距离阈值。

12.3 带责任边界的闭环仲裁

ACT 负责名义技能，恢复 actor 负责高风险区域，状态机负责明确切换；hand-off 时清除 ACT 动作块，恢复 option 持续到任务成功或预算结束。创新位于策略组合与分布对齐，而非声称发明了 Transformer、LSTM 或 MLP。

如果用于 EI 会议摘要，可以概括为：

REIM introduces a trigger-aligned corrective imitation pipeline and a causal temporal arbitration mechanism that selectively transfers control from a chunked nominal policy to a persistent recovery option under execution disturbances.

13. 当前证据边界与局限

13.1 单任务

目前只在 Meta-World PickPlace 上验证。结果证明的是该任务上的机制有效性，不证明跨任务普适性。

13.2 使用 privileged state

21 维输入包含精确关节、物体和目标位置；恢复数据采集还需要完整 MuJoCo snapshot。它适合受控仿真实验，但真实机器人需要视觉/力觉状态估计和安全的数据收集流程。

13.3 主要是早期纠偏

恢复起点审计显示训练触发的 98.9% 和验证触发的 99.0% 位于首次 lift 之前。因此当前系统主要纠正抓取前接近或物体扰动后的轨迹，不能声称已经解决任意 post-drop recovery。

13.4 监测器并非长时域预言器

标准 confusion matrix 中大量正样本是当前事件窗口；严格 pre-event F1 为 60.0%，提前量中位数为 1 步。检测模块需要依赖闭环结果而不是单独指标来证明价值。

13.5 单个训练模型栈

主表在一个训练好的 ACT、LSTM 和恢复 actor 上使用大量配对测试种子，充分估计执行随机性，但没有传播多次模型训练带来的不确定性。进一步投稿可以训练 3-5 组独立模型种子。

13.6 恢复成功定义

当前 recovery rate 是“恢复控制仍激活时任务完成”，不是“恢复到经过认证的安全集后交回 ACT”。持久 option 的效果很好，但还没有证明可验证的安全 hand-back。

14. 复现实验的完整流程

14.1 安装

```
cd REIM
./setup.sh
source .venv/bin/activate
```

14.2 从头运行

```
./run_all.sh --full
```

默认主流程依次执行：

54. 收集 500 条专家示范；

55. 训练状态版 ACT;
56. 生成 2,000 条扰动 rollout;
57. 训练因果 LSTM;
58. 采集训练/验证恢复触发 bank;
59. 训练并导出监督恢复 actor;
60. 生成冻结 CRN episode bank;
61. 运行四方法主比较;
62. 运行鲁棒性、消融和门控敏感性;
63. 生成图表、LaTeX 表格、论文 PDF 和审计 manifest。

14.3 复用已有训练结果

```
./run_all.sh --full --resume --skip-data --skip-training
```

14.4 核验

```
python -m pytest -q
python scripts/update_paper_results.py --check-only
python scripts/reproducibility_manifest.py
./compile_paper.sh
```

正式证据入口:

- results/tables/baseline.csv
- results/tables/baseline_episodes.csv
- results/tables/robustness.csv
- results/tables/gate_matched_comparison.json
- results/run_manifest.json
- paper_assets/reim_results.pdf

15. 代码地图

功能	主要文件
Meta-World 环境、状态与扰动	env/metaworld_pickplace.py
ACT 网络	models/bc_policy.py
ACT 训练	trainers/train_bc.py
失败标签	data/failure_labels.py
失败数据生成	scripts/generate_failures.py
LSTM 风险监测器	models/failure_detector.py
LSTM 训练	trainers/train_detector.py
触发 snapshot/专家 continuation	scripts/collect_recovery_starts.py
恢复 actor	models/imitation_recovery_policy.py
恢复训练与导出	trainers/train_recovery.py,

	scripts/export_imitation_recovery.py
闭环状态机	evaluation/evaluate_reim.py
四方法比较	evaluation/baseline.py
冻结 episode bank	evaluation/episode_bank.py, scripts/generate_episode_bank.py
鲁棒性与消融	experiments/robustness.py, experiments/ablation.py
论文图表	visualization/plot_results.py
一键流水线	run_all.sh

16. 答辩常见问题

Q1：为什么不用一个统一策略从正常状态一直学到失败状态？

统一策略需要同时覆盖高密度的成功示范分布和稀疏、异质的失败分布，训练目标容易互相干扰。REIM 用门控保留 ACT 的名义能力，只在高风险区域调用专门的恢复 actor，数据需求和责任边界更清楚。

Q2：为什么 LSTM 只看 10 步？

10 步足以覆盖短期接近、物体位移和进展停滞信号，同时保持检测延迟和模型规模较小。该长度由项目配置冻结，后续可作为超参数做系统消融。

Q3：为什么恢复采集阈值是 0.10，部署是 0.20？

采集阶段希望覆盖更宽的可恢复状态，因此使用低阈值；部署阶段需要控制误触发和干预成本，因此使用更保守的阈值。训练数据覆盖应当宽于最终控制器的工作区域。

Q4：恢复策略为什么不用失败标签作为额外输入？

恢复 actor 的训练分布本身已经由 LSTM 触发筛选，failure awareness 体现在 sampling distribution，而不是一个可能被模型忽略的二值 mode bit。部署时 actor 只需要当前 21 维状态。

Q5：既然恢复 actor 来源中出现过 SB3 容器，为什么不是 PPO？

算法属性由实际优化和导出的模型决定。正式 actor 只有监督 Smooth L1 训练、0 环境训练步和 0 policy-gradient update；导出文件没有 critic/optimizer，因此必须称为监督模仿。

Q6：90.4% 是否来自重新尝试多个随机任务？

不是。主表所有方法共享同一 1,000 个冻结初始状态和扰动 schedule。只有 Random Reset baseline 按定义获得一个明确标注的 fresh-task retry。

Q7：为什么恢复率 85.3% 小于总成功率 90.4%？

总成功率包含没有触发恢复、由 ACT 直接完成的 episode。恢复率的分母仅是发生恢复干预的 655 个 episode，其中 559 个在恢复控制期间成功。

Q8：这能否称为实体机器人实验？

不能。所有图片来自 Meta-World/MuJoCo 的模拟 Sawyer。实体 Sawyer 需要相机/力觉、状态估计、真实扰动和安全实验协议。

Q9：最应该追加什么实验？

优先级依次是：多训练种子、专门的 post-grasp/drop curriculum、多个 Meta-World 任务、视觉状态估计、实体 Sawyer 小规模验证。

17. 最后一句话

REIM 的价值不在于把 ACT、LSTM 和 MLP 并列放在一张图里，而在于建立了一个可审计的选择性恢复机制：**用 ACT 学正常任务，用因果时序风险决定何时离开正常策略，再用真实触发状态上的专家 continuation 学会如何把任务救回来。**